

Grupo de Doenças Cardíacas

Equipe: Angelus, Rafael, José, Matheus

Descrição do problema

O estudo se refere a uma predição sobre doenças cardíacas com base em 4 datasets diferentes (Cleveland, Hungary, Switzerland, VA Long Beach - Cleveland é o mais promissor), contendo 76 atributos (14 usáveis).

Tem como objetivo determinar em uma escala de 0 a 4, a probabilidade de incidência de doença cardíaca no paciente.

Stakeholders

Os principais stakeholders envolvidos podem ser:

- Profissionais da área da saúde
- Cardiologistas (Especialista da área)
- Técnicos em radiologia
- Administradores hospitalares envolvidos no fluxo de aprovações de exames
- Desenvolvedores de Wearables de Saúde

Outros datasets relevantes

Marts de Medicina:

- <https://physionet.org/content/mimiciv/2.2/>

Predição de Ataque Cardíaco:

- <https://www.kaggle.com/datasets/fedesoriano/heart-failure-prediction/data>

Casos de Ataque Cardíaco:

- <https://archive.ics.uci.edu/dataset/519/heart+failure+clinical+records>

Estudo cardíaco de Framingham:

- <https://www.kaggle.com/datasets/aasheesh200/framingham-heart-study-dataset>

Descobertas relacionadas ao projeto

Em 1948, surgiu o estudo de coração de Framingham - com o uso de estatística.

E então se percebeu correlação com:

- Fumo
- Hipertensão
- Colesterol alto
- Risco por obesidade
- Diabetes
- Falta de exercício físico

Dicionário de dados

Col. Base Orig.	Nome da Coluna	Descrição
#3	(age)	Idade (inteiro)
#4	(sex)	Sexo: 0=fem, 1=masc
#9	(cp)	Tipo de dor no peito: 1=angina usual, 2=angina atípica, 3=não anginal, 4=assintomático (sem dor)
#10	(trestbps)	Pressão sang. em repouso (mmHG na admissão)
#12	(chol)	Colesterol (mg/dl)
#16	(fbs)	Nível de açúcar em jejum: 0=abaixo de 120mg/dl, 1=acima de 120mg/dl
#19	(restecg)	Eletrocardiograma em repouso: 0=normal, 1=anormalidade, 2=provavel hipertrofia ventricular
#32	(thalach)	Frequência cardíaca máxima atingida
#38	(exang)	Angina induzida por exercício: 0=não, 1=sim
#40	(oldpeak)	Depressão do segmento ST induzida por exercício (inteiro)
#41	(slope)	Inclinação do pico do segmento ST durante exercício: 1=positiva, 2=reta, 3=negativa
#44	(ca)	Número de vasos principais que continham cálcio: 0 a 3 (inteiro)
#51	(thal)	Defeito cintilográfico com tálcio: 3= normal, 6=defeito fixo, 7= defeito reversível
#58	(num)	Diagnóstico de doença cardíaca: 0: <50% de redução do diametro, >1:>50% de redução do diametro

Visualizando nosso dataset

A base de dados utilizada já é reduzida da base original, que continha 76 atributos.

	age	sex	cp	trestbps	chol	fbs	restecg	thalach	exang	oldpeak	slope	ca	thal	target
0	63	1	1	145	233	1	2	150	0	2.3	3	0.0	6.0	0
1	67	1	4	160	286	0	2	108	1	1.5	2	3.0	3.0	2
2	67	1	4	120	229	0	2	129	1	2.6	2	2.0	7.0	1
3	37	1	3	130	250	0	0	187	0	3.5	3	0.0	3.0	0
4	41	0	2	130	204	0	2	172	0	1.4	1	0.0	3.0	0
5	56	1	2	120	236	0	0	178	0	0.8	1	0.0	3.0	0
6	62	0	4	140	268	0	2	160	0	3.6	3	2.0	3.0	3
7	57	0	4	120	354	0	0	163	1	0.6	1	0.0	3.0	0
8	63	1	4	130	254	0	2	147	0	1.4	2	1.0	7.0	2
9	53	1	4	140	203	1	2	155	1	3.1	3	0.0	7.0	1

Análise descritiva


	age	sex	cp	trestbps	chol	fb	restecg	thalach	exang	oldpeak	slope	ca	thal	target
count	303	303	303	303	303	303	303	303	303	303	303	299	301	303
mean	54,44	0,68	3,16	131,69	246,69	0,15	0,99	149,61	0,33	1,04	1,60	0,67	4,73	0,94
std	9,04	0,47	0,96	17,60	51,78	0,36	0,99	22,88	0,47	1,16	0,62	0,94	1,94	1,23
min	29	0	1	94	126	0	0	71	0	0	1	0	3	0
25%	48	0	3	120	211	0	0	133,5	0	0	1	0	3	0
50%	56	1	3	130	241	0	1	153	0	0,8	2	0	3	0
75%	61	1	4	140	275	0	2	166	1	1,6	2	1	7	2
max	77	1	4	200	564	1	2	202	1	6,2	3	3	7	4

Distribuição do target: 0=164, 1=55, 2=36, 3=35, 4=13


Redução da base

Através da análise de correlações é possível ver que 2 variáveis numéricas possuem baixa correlação com o target.


Porém pelo baixo número de features numéricas não vamos removê-las.




Histograma





Dispersão de colunas numéricas




Dispersão de colunas categóricas



Box Plot




Distribuição da doença baseada na idade



Ausência: target = 0;

Presença: target > 0.

Distribuição da doença baseada em ECG




Ausência: target = 0;

Presença: target > 0.

Limpeza da base



Poucos valores nulos, que não devem influenciar caso sejam removidos, por não influenciarem fortemente no balanço entre os dados target.

A remoção de valores nulos resulta numa redução de 303 instâncias para 297




Transformação da base

Desbalanceamento de classes, devemos considerar o balanço de ausência (valor 0) e presença (valores de 1 a 4)



Modelo Decision Tree


Modelo sem o balanceamento de classes (Treino:80%, Teste:20%, com oversampling)



	precision	recall	f1-score	support
0	0.67	0.75	0.71	32
1	0.00	0.00	0.00	11
2	0.20	0.14	0.17	7
3	0.17	0.14	0.15	7
4	0.00	0.00	0.00	3
accuracy			0.43	60
macro avg	0.21	0.21	0.21	60
weighted avg	0.40	0.43	0.41	60


Modelo Decision Tree

Modelo sem o balanceamento de classes (Treino:80%, Teste:20%, com oversampling)



Modelo Decision Tree


Modelo com o balanceamento de classes (Treino:80%, Teste:20%, sem oversampling)



	precision	recall	f1-score	support
0	0.71	0.75	0.73	32
1	0.69	0.64	0.67	28
accuracy			0.70	60
macro avg	0.70	0.70	0.70	60
weighted avg	0.70	0.70	0.70	60

Modelo Decision Tree


Modelo com o balanceamento de classes (Treino:80%, Teste:20%, sem oversampling)



Modelo K-Means

Avaliação de grupos para K-Means = 2, com redução PCA

Método do Cotovelo



KMeans Clusters with Centroids

